

Longitudinal EHR Disease State Prediction

数据集构建与评估指标设计文档 - Codex 实现版

目标：基于 MIMIC-IV 构建一个可复现的 EHR 病情状态预测任务，支持全局状态、多器官状态、未来风险事件和证据解释的联合评估。

给 Codex 的核心要求：先完成结构化数据弱标签 + 规则 evidence + baseline + metrics 的 MVP；note 输入与 LLM judge 作为第二阶段扩展。

参考数据源：[MIMIC-IV PhysioNet](#)；[MIMIC-IV-Note PhysioNet](#)；[MIMIC-IV paper](#)

工程流程总览

阶段	输入	输出	主要脚本
1. Cohort	MIMIC-IV 原始表	cohort.parquet	01_build_cohort.py
2. Sampling	ICU stay + anchor hours	样本时间窗	02_build_dataset.py
3. Labeling	target window 事件/指标	global/organ/risk/evidence labels	labels/*.py
4. Baselines	train/valid/test.jsonl	predictions/*.jsonl	03_run_baseline.py
5. Evaluation	gold + prediction	metrics.json / metrics.md	04_evaluate.py

1. 项目目标与任务定义

任务名称建议：Longitudinal EHR Disease State Prediction / Patient Trajectory State Forecasting from EHR。
给定患者从 ICU 入院到预测时刻 t 的纵向 EHR 轨迹，预测未来窗口 t 到 t+Δt 内的病情状态。该任务不是单纯死亡率预测，而是更细粒度地预测 “全局病情 + 多器官状态 + 未来风险事件 + 支撑证据”。

任务形式化

输入：患者从 ICU admission 到 anchor time t 的 EHR 历史
输出：未来 horizon 内的病情状态

默认设置：

- anchor time: 24h, 48h, 72h
- horizon: next 24h
- time bin: 6h
- split: by subject id

输出部分	含义	建议标签/类型
global_state	患者整体病情趋势	improving / stable / worsening / mixed / critical / recovering
organ_states	多器官系统状态	improving / stable / worsening / unknown
risk_events	未来 24h 临床事件	binary 或 probability
evidence	规则触发证据	deterministic text evidence

2. 数据源与最小可用输入

MIMIC-IV 的 hosp 模块来源于医院范围 EHR，icu 模块来源于 ICU MetaVision 系统；MIMIC-IV-Note 提供去标识化临床自由文本 notes。第一版应保证在无 note 的情况下也能运行。

类别	MIMIC-IV 表	用途
人口学/住院	hosp/patients, hosp/admissions	年龄、性别、住院死亡时间、入出院时间
ICU stay	icu/icustays	stay_id、intime、outtime、ICU LOS
生命体征/护理记录	icu/chartevents, icu/d_items	HR、BP、MAP、SpO2、GCS、FiO2 等
实验室	hosp/labevents	WBC、lactate、creatinine、BUN、platelets 等
用药/液体	icu/inputevents, hosp/prescriptions	升压药、抗生素、输入量
操作/输出	icu/procedureevents, icu/outputevents	机械通气、RRT、尿量等
可选 notes	note/discharge, note/radiology 等	自然语言输入和证据扩展

预期数据目录

```
mimiciv/  
  hosp/  
    patients.csv.gz  
    admissions.csv.gz  
    diagnoses_icd.csv.gz  
    procedures_icd.csv.gz  
    labevents.csv.gz  
    prescriptions.csv.gz  
    microbiologyevents.csv.gz  
  icu/  
    icustays.csv.gz  
    chartevents.csv.gz  
    inputevents.csv.gz  
    procedureevents.csv.gz  
    outputevents.csv.gz  
    d_items.csv.gz  
  note/ optional  
    discharge.csv.gz  
    radiology.csv.gz
```

3. 工程目录结构

```
ehr_state_prediction/
```

```
README.md
requirements.txt
config/default.yaml
src/
  data/
    load_mimic.py
    item_mappings.py
    cohort.py
    extract_events.py
    build_samples.py
    serialize_dataset.py
  labels/
    rule_global_state.py
    rule_organ_states.py
    rule_risk_events.py
    rule_evidence.py
  features/
    timeline_builder.py
    text_formatter.py
    structured_formatter.py
  models/
    heuristic_baseline.py
    sklearn_baseline.py
    llm_prompt_baseline.py
  evaluation/
    metrics_global.py
    metrics_organ.py
    metrics_risk.py
    metrics_evidence.py
    metrics_temporal.py
    evaluate.py
  utils/
    time_utils.py
    io_utils.py
    logging_utils.py
  scripts/
    01_build_cohort.py
    02_build_dataset.py
    03_run_baseline.py
    04_evaluate.py
  outputs/
    dataset/
    predictions/
    reports/
```

4. Cohort 与样本生成

规则类型	默认设置
纳入标准	adult age >= 18; ICU LOS >= 48h; 有 valid stay_id; 前 24h 有结构化 chart/lab events
排除标准	缺失 ICU intime/outtime; ICU stay 短于 observation + horizon; 可选仅保留每次住院首个 ICU stay
样本锚点	anchor_hours = [24, 48, 72]
目标窗口	prediction_horizon = next 24h
时间零点	所有时间均以 ICU intime 为 t=0

样本生成逻辑

```
for each ICU stay:
  for anchor_hour in [24, 48, 72]:
    observation_window = [intime, intime + anchor_hour]
    target_window = [intime + anchor_hour, intime + anchor_hour + horizon_hour]
    if target_window exceeds ICU outtime:
      skip
    build sample_id = f"{subject_id}_{hadm_id}_{stay_id}_t{anchor_hour}_h{horizon_hour}"
```

5. 输入构造：结构化 timeline + LLM text

第一版同时保存结构化 JSON 和文本化 input_text。结构化版本用于 sklearn/deep baseline，文本版本用于 LLM prompt 或 agent。

器官/系统	核心变量
Cardiovascular	heart_rate, systolic_bp, diastolic_bp, mean_bp, lactate, vasopressors
Respiratory	respiratory_rate, SpO2, FiO2, PaO2, ventilation_status, oxygen_device
Renal	creatinine, BUN, urine_output, RRT/dialysis
Infectious	temperature, WBC, antibiotics, cultures, microbiology
Neurological	GCS, mental_status, sedation_caveat
Hematologic	platelets, hemoglobin, INR, PT, PTT

6 小时时间 bin 格式

```
{
  "start_hour": 0,
  "end_hour": 6,
  "vitals": {},
  "labs": {},
  "medications": [],
  "procedures": [],
  "outputs": {},
  "notes": []
}
```

6. Label 构建规则

注意：label 构建可以使用 target window 的未来信息；模型输入绝不能使用 target window 的未来信息。

每个器官系统使用 observation window 末段 baseline 与 target window 的 future value 进行比较。推荐：baseline = anchor 前最后 6h 的 median 或 last valid；future = target window 的 worst value 或 median。

器官	worsening 触发	improving 触发
Cardiovascular	新用/升级升压药；lactate 增加 >=2 或 >=30%；MAP <65 并有低灌注	升压药停用/下降；lactate 下降 >=20%；MAP 稳定或改善
Respiratory	新机械通气；氧支持升级；FiO2 上升；SpO2 持续下降	拔管；氧支持下降；FiO2 下降且 SpO2 稳定
Renal	新 RRT；Cr 增加 >=0.3 或 >=50%；尿量低于 oliguria 阈值	Cr 下降 >=20%；尿量改善；无新 RRT
Infectious	发热/低温加重；WBC 增加 >=30%；新阳性培养合并恶化；抗生素升级	体温正常化；WBC 下降 >=20%；无 sepsis escalation
Neurological	GCS 下降 >=2 且非镇静解释；新昏迷/癫痫/卒中文档	GCS 上升 >=2；精神状态改善
Hematologic	血小板下降 >=30%；Hb 明显下降；INR/PT/PTT 恶化	血小板恢复；凝血指标改善

Global state 规则

```
if death_in_target_window:
    global_state = "critical"
elif sofa_increase_ge_2 or number_of_worsening_organs >= 2:
    global_state = "worsening"
elif number_of_improving_organs >= 2 and number_of_worsening_organs == 0:
    global_state = "improving"
elif number_of_improving_organs >= 1 and number_of_worsening_organs >= 1:
    global_state = "mixed"
elif icu_transfer_out_in_target_window and number_of_worsening_organs == 0:
    global_state = "recovering"
else:
    global_state = "stable"
```

7. Risk Events 与 Evidence

risk_event	定义
mortality	target window 内死亡
icu_transfer_out	target window 内 ICU outtime, 且非死亡转出
mechanical_ventilation_start	target window 出现机械通气, anchor 前不存在
vasopressor_start_or_escalation	target window 新用升压药或剂量明显增加
rrt_start	target window 新开始 dialysis/RRT
sofa_increase_ge_2	target window SOFA - anchor 前 SOFA >= 2; 若未实现 SOFA 则设 missing

Deterministic evidence 生成

```
def make_evidence(variable, old_value, new_value, unit, direction):
    return f"{variable} {direction} from {old_value} to {new_value} {unit}"

Example:
"creatinine increased from 2.3 to 3.1 mg/dL"
"norepinephrine was discontinued"
"lactate decreased from 4.1 to 1.8 mmol/L"
```

8. 数据集输出格式

full JSONL 单样本格式

```
{
  "sample_id": "10000032_20000001_30000001_t48_h24",
  "subject_id": 10000032,
  "hadm_id": 20000001,
  "stay_id": 30000001,
  "prediction_time_hours": 48,
  "observation_window": [0, 48],
  "prediction_horizon": [48, 72],
  "input": {
    "demographics": {},
    "diagnoses": [],
    "procedures": [],
    "medications": [],
    "timeline": []
  },
  "label": {
    "global_state": "mixed",
    "organ_states": {
      "cardiovascular": "improving",
      "respiratory": "stable",
      "renal": "worsening",
      "infectious": "improving",
      "neurological": "unknown",
      "hematologic": "worsening"
    },
    "risk_events": {},
    "evidence": {},
    "label_debug": {}
  }
}
```

文件	用途
ehr_state_prediction_full.jsonl	完整样本, 包含结构化 input、labels、evidence、debug
ehr_state_prediction_text.jsonl	LLM prompting: sample_id、input_text、target_json
ehr_state_prediction_structured.parquet	sklearn/deep baseline: feature columns + labels
train.jsonl / valid.jsonl / test.jsonl	按 subject_id 划分后的 split 文件

9. Baseline 模型

Baseline	输入	预测目标	注意事项
Heuristic baseline	observation window 内近期趋势	global + organ + risk	不能使用 target window; 仅用

Baseline	输入	预测目标	注意事项
	势		历史趋势推断未来
Last-trend baseline	最近 24h trend	organ_states	future state = recent observed trend
Sklearn baseline	last/mean/min/max/slope/missing/count features	global、每个器官、每个 risk event	global 用多分类；risk 用二分类概率

```
Prediction JSONL format:
{
  "sample_id": "...",
  "pred": {
    "global_state": "mixed",
    "organ_states": {
      "cardiovascular": "improving",
      "respiratory": "stable",
      "renal": "worsening"
    },
    "risk_events": {
      "mortality": 0.12,
      "rrt_start": 0.33
    },
    "evidence": {
      "renal": ["creatinine increased during the observation window"]
    }
  }
}
```

10. 评估指标设计

主指标建议：Global Macro-F1 + Organ-Macro-F1 + Evidence F1；完整报告再加入 risk、temporal robustness 和 DSPS。

评估对象	指标	实现文件
Global state	Accuracy, Macro-F1, Weighted-F1, Balanced Accuracy, Cohen Kappa	metrics_global.py
Organ states	Per-organ Macro-F1, Organ-Macro-F1, Organ-State Accuracy	metrics_organ.py
Trend direction	Directional Accuracy, State Distance Error	metrics_organ.py
Risk events	AUROC, AUPRC, F1@0.5, Sensitivity, Specificity	metrics_risk.py
Evidence	Evidence Precision/Recall/F1 using approximate string matching	metrics_evidence.py
Prediction-evidence consistency	Keyword/rule-based consistency score 0/0.5/1	metrics_evidence.py
Temporal robustness	Performance drop under timeline perturbations	metrics_temporal.py

方向性指标

```
STATE_DIRECTION = {
  "improving": 1,
  "stable": 0,
  "worsening": -1
}

Directional Accuracy = correct_directions / evaluated_organ_states
State Distance Error = mean(abs(value[y_true] - value[y_pred]))
```

Composite metric: Disease State Prediction Score

```
DSPS = (
  0.35 * global_macro_f1
+ 0.35 * organ_macro_f1
+ 0.15 * evidence_f1
+ 0.10 * prediction_evidence_consistency
+ 0.05 * risk_event_mean_auprc
)
```

11. CLI 命令与配置

```
python scripts/01_build_cohort.py --mimic_dir /path/to/mimiciv --output_dir outputs/dataset

python scripts/02_build_dataset.py --mimic_dir /path/to/mimiciv --cohort_path
outputs/dataset/cohort.parquet --output_dir outputs/dataset --anchor_hours 24 48 72 --
horizon_hours 24 --bin_hours 6

python scripts/03_run_baseline.py --train_path outputs/dataset/train.jsonl --valid_path
outputs/dataset/valid.jsonl --test_path outputs/dataset/test.jsonl --model heuristic --output_path
outputs/predictions/heuristic_test.jsonl

python scripts/04_evaluate.py --gold_path outputs/dataset/test.jsonl --pred_path
outputs/predictions/heuristic_test.jsonl --output_dir outputs/reports
```

config/default.yaml

```
data:
  mimic_dir: "/path/to/mimiciv"
  output_dir: "outputs/dataset"

cohort:
  min_age: 18
  min_icu_los_hours: 48
  use_first_icu_stay_only: false

sampling:
  anchor_hours: [24, 48, 72]
  horizon_hours: 24
  bin_hours: 6

labels:
  organs:
    - cardiovascular
    - respiratory
    - renal
    - infectious
    - neurological
    - hematologic
  ignore_unknown_in_metrics: true

splits:
  train: 0.7
  valid: 0.1
  test: 0.2
  split_by: "subject_id"
  random_seed: 42

evaluation:
  primary_metric: "DSPS"
  evidence_match_threshold: 0.5
```

12. MVP 实现清单

优先级	模块	验收标准
P0	Cohort 构建	能生成 adult ICU stay cohort；统计纳入/排除数量
P0	样本生成	按 anchor_hours 生成样本；不泄露 target window 到 input
P0	Organ labels	至少实现 cardiovascular/respiratory/renal/infectious/hematologic
P0	Global labels	根据器官状态、死亡、ICU 转出、SOFA 可选生成 global_state
P0	Evidence	每个规则触发 label_debug 和 deterministic

优先级	模块	验收标准
		evidence
P0	Evaluation	输出 metrics.json 和 metrics.md; unknown 标签可忽略并计数
P1	Baselines	heuristic、last-trend、sklearn logistic regression 可运行
P1	Temporal robustness	支持删除/打乱/mask 输入后的性能下降评估
P2	Note 输入	加入 MIMIC-IV-Note 作为 input_text 扩展

最小成功标准：运行 01-04 脚本后，outputs/dataset、outputs/predictions、outputs/reports 下均有可复现文件；test set 可得到 Global Macro-F1、Organ-Macro-F1、Directional Accuracy、Risk AUPRC、Evidence F1、DSPS。

13. 关键实现注意事项

- 所有时间比较必须以 ICU intime 为 time zero。
- 模型输入绝不能包含 target window 的数据；标签构建允许使用 target window。
- split 必须按 subject_id，而不是 sample_id，避免同一患者泄露到多个 split。
- 所有 rule label 都必须保存 label_debug，便于追踪规则触发原因。
- 缺失数据不应导致 pipeline 崩溃；缺失严重时标记 unknown。
- 评估时 report 应输出 unknown 被忽略的数量与比例。
- 如果某个 risk event 在 test set 只有一个类别，跳过 AUROC/AUPRC 并记录 warning。
- 所有随机过程固定 random_seed，保证复现实验。

14. 参考资料

1. MIMIC-IV v3.1, PhysioNet: <https://physionet.org/content/mimiciv/>
2. MIMIC-IV-Note: Deidentified free-text clinical notes v2.2, PhysioNet: <https://www.physionet.org/content/mimic-iv-note/2.2/>
3. Johnson et al. MIMIC-IV, a freely accessible electronic health record dataset. Scientific Data / Nature: <https://www.nature.com/articles/s41597-022-01899-x>
4. MIMIC official website and module documentation: <https://mimic.mit.edu/>

Appendix: 可直接复制给 Codex 的任务描述

请根据本文档实现一个 Python 项目 `ehr_state_prediction`，用于基于 MIMIC-IV 构建 Longitudinal EHR Disease State Prediction 数据集，并完成 baseline 与评估。

第一阶段 MVP 必须实现：

1. cohort 构建: adult ICU stays, ICU LOS $\geq 48h$ 。
2. sample 构建: anchor_hours=[24,48,72], horizon=24h, bin=6h。
3. structured input 和 input_text 输出。
4. rule-based organ labels: cardiovascular、respiratory、renal、infectious、hematologic。
5. global_state label: improving/stable/worsening/mixed/critical/recovering。
6. risk_events: mortality、icu_transfer_out、mechanical_ventilation_start、vasopressor_start_or_escalation、rrt_start、sofa_increase_ge_2 可选。
7. deterministic evidence 与 label_debug。
8. patient-level train/valid/test split。
9. baselines: heuristic、last-trend、sklearn logistic regression。
10. metrics: Global Macro-F1、Organ-Macro-F1、Directional Accuracy、State Distance Error、Risk AUPRC、Evidence F1、Prediction-Evidence Consistency、DSPS。
11. CLI scripts: 01_build_cohort.py、02_build_dataset.py、03_run_baseline.py、04_evaluate.py。

请优先保证代码清晰、模块化、可复现，并在 README 中说明运行方式和每个指标的含义。